

# Projekt planu badawczego

w postępowaniu rekrutacyjnym

do Szkoły Doktorskiej w Uniwersytecie Śląskim w Katowicach

na rok akademicki 2025/2026

**Imię i nazwisko osoby kandydującej:** Bartłomiej Rokowski

**Dyscyplina naukowa/artystyczna:** Bioinformatyka

*Informacja:*

1. Opis projektu planu badawczego nie może przekraczać 12 tysięcy znaków (ze spacjami; liczona jest tylko merytoryczna treść wprowadzona przez kandydata, bez literatury). Opisy dłuższe nie będą rozpatrywane w postępowaniu.
2. Projekt powinien zostać zaopiniowany przez opiekuna naukowego (który zgodził się pełnić funkcję promotora lub promotora pomocniczego osoby kandydującej, będącego pracownikiem badawczo-dydaktycznym lub badawczym Uniwersytetu Śląskiego w Katowicach). Opiekun sporządza opinię na temat profilu naukowego osoby kandydującej i jej projektu w osobnym dokumencie i przekazuje ją osobie kandydującej.
3. Gotowy projekt należy zapisać w formacie pdf i wprowadzić do systemu IRK najpóźniej do 20 czerwca 2025 r. do godz. 15:00 (zgodnie z harmonogramem rekrutacji).

**Temat projektu:**

**Sztuczna inteligencja w diagnostyce obrazowej: opracowanie i ocena skuteczności systemu do automatycznej detekcji schorzeń na obrazach RTG, TK, RM i mammografii**

**Cel naukowy projektu:**

*Proszę opisać problem naukowy, który jest podejmowany. Proszę wskazać pytania lub hipotezy badawcze.*

Celem projektu jest wsparcie służby zdrowia w Polsce poprzez opracowanie zaawansowanego systemu AI do automatycznego wykrywania schorzeń na obrazach RTG, TK, RM oraz mammografii. Projekt zakłada stworzenie narzędzia do analizy obrazów medycznych, identyfikacji i klasyfikacji patologii, takich jak guzy, zmiany zapalne i zwyrodnieniowe.

System będzie wykorzystywany do:

1. Automatycznego rozpoznawania patologii: Identyfikacja różnych rodzajów nieprawidłowości na obrazach medycznych.
2. Wsparcia diagnostyki: Narzędzie dla radiologów do szybszego i dokładniejszego wykrywania schorzeń, co może prowadzić do wcześniejszej diagnozy i lepszego leczenia.
3. Standaryzacji opisów medycznych: Model standardowego opisu obrazów medycznych, umożliwiający jednolite raportowanie i lepszą komunikację między placówkami.

Główne pytanie badawcze: czy algorytmy AI mogą równie skutecznie i niezawodnie co ludzie wykrywać schorzenia na obrazach RTG, TK, RM i mammografii?

## **Znaczenie projektu dla dyscypliny:**

*Proszę uzasadnić podjęcie badań w tym zakresie. Co świadczy o nowatorstwie projektu?*

Wykorzystanie sztucznej inteligencji w diagnostyce obrazowej to dynamicznie rozwijająca się dziedzina. Dotychczasowe badania skupiają się jednak głównie na pojedynczych modalnościach, takich jak RTG czy rezonans magnetyczny, co ogranicza możliwości AI w praktyce klinicznej.

Projekt zakłada stworzenie kompleksowego systemu AI analizującego obrazy RTG, TK, RM i mammografii. Odpowiada on na realne potrzeby zwiększenia efektywności diagnostyki, obciążenia radiologów i poprawy wykrywalności chorób. Celem jest nie tylko opracowanie nowoczesnego narzędzia klinicznego, ale też ocena, jak AI radzi sobie w porównaniu z lekarzami specjalistami. Badania pozwolą określić, czy system może osiągać podobną lub wyższą skuteczność oraz w jakich sytuacjach najlepiej wspierać decyzje medyczne.

Ocena skuteczności systemu ma kluczowe znaczenie — pomoże wskazać jego potencjalne zastosowania w praktyce: jako narzędzie wspomagające lekarzy, system triażowy czy rozwiązanie dla placówek z ograniczonym dostępem do specjalistów. Pozwoli także opracować rekomendacje wdrożeniowe i zidentyfikować obszary, w których AI przynosi największe korzyści.

Projekt wyróżnia się modułową architekturą, ułatwiającą rozbudowę o nowe funkcje diagnostyczne oraz integracją wielu modalności obrazowych w jednym systemie, co jest rzadkością na świecie. Umożliwi to bardziej kompleksową ocenę stanu pacjenta i zwiększy trafność diagnoz.

Dodatkowo system może przyczynić się do standaryzacji opisów medycznych, usprawniając komunikację między placówkami i analizę danych na szerszą skalę. Dzięki AI możliwe będzie szybsze i dokładniejsze wykrywanie schorzeń, co przełoży się na wyższą jakość opieki oraz efektywniejsze wykorzystanie zasobów ochrony zdrowia.

## **Ogólny plan badań:**

*Proszę opisać przewidywane etapy postępowania badawczego.*

Plan badań obejmuje kilka etapów:

1. Analiza literatury i istniejących rozwiązań: Przegląd badań i technologii w zakresie AI w diagnostyce obrazowej.
2. Kompletowanie i przygotowanie danych: Gromadzenie zbiorów danych obrazowych z TK, RM i mammografii oraz ich anotacja i sprawdzenie przez specjalistów.
3. Rozwój modeli AI: Projektowanie i trenowanie modeli sieci neuronowych AI na zebranych danych, wykorzystując techniki głębokiego uczenia.
4. Walidacja i optymalizacja: Testowanie modelu na niezależnych zestawach danych, optymalizacja parametrów i poprawa dokładności.
5. Stworzenie systemu: Integracja wyuczonych modeli AI, stawiających finalną diagnozę oraz generującego ustandaryzowany opis z analizy obrazów.

6. Ewaluacja i skalowanie: Ocena skuteczności systemu i porównanie z wynikami specjalistów.

Analiza ryzyka: Kluczowe ryzyka obejmują:

- a) Niewystarczającą ilość i jakość danych treningowych do osiągnięcia zakładanej minimum 75% poprawności w diagnozach modeli AI.
- b) Akceptacja systemu, jego interfejsu i generowanych opisów diagnostycznych przez specjalistów medycznych.

Rozwiązania:

- a) Ciągła weryfikacja parametrów jakościowych oraz wolumenu danych wejściowych. Zbiór danych treningowych będzie na bieżąco powiększany i oceniany. W razie problemów podejmowane będą natychmiastowe działania naprawcze.
- b) Konsultacje ze specjalistami medycznymi dotyczące informacji zwracanych przez system oraz wyglądu i działania interfejsu na każdym etapie prac.

**Kamienie milowe:**

KAM.1. ZEBRANIE DANYCH DO UCZENIA MODELI AI.

- Ocena: Pozyskanie i kompletowanie oznaczonych przez specjalistów obrazów RM, TK i mammografii do uczenia modeli AI.
- Forma: Raport z informacjami o przygotowanych zbiorach danych, w tym ilości obrazów, rozdzielczościach, formatach plików i oznaczonych schorzeniach.

KAM.2. OPRACOWANA METODA ANALIZY OBRAZÓW TK, RM, MAMMOGRAFII.

- Ocena: Modele AI z min. 75% poprawności wykrywania schorzeń na obrazach.
- Forma: Raport z analizami i wynikami testów walidacyjnych modeli AI.

KAM.3. PROTOTYP SYSTEMU ANALIZUJĄCY OBRAZY MODELI AI.

- Ocena: Prototyp systemu łączący modele AI, osiągający min. 75% poprawnych diagnoz na zbiorze testowym z co najmniej 3 schorzeniami.
- Forma: Raport z działania prototypu, zawierający wyniki diagnoz i analizę wyników.

KAM.4. MODEL OPISU SCHORZEŃ OBRAZÓW TK, RM, MAMMOGRAFII.

- Ocena: Szablon generowanego przez system opisu uznany przez 2 z 3 konsultowanych ekspertów za zgodny z metodologią.
- Forma: Raport z opisem szablonu opisowego i opiniami ekspertów.

KAM.5. PEŁNA WERSJA SYSTEMU Z INTERFEJSEM.

- Ocena: System identyfikujący min. 5 rodzajów schorzeń na min. 3 różnych badaniach obrazowych z min. 75% poprawności i generujący akceptowalne przez ekspertów opisy.
- Forma: Raport z wynikami diagnoz i opiniami specjalistów o działaniu systemu, jego interfejsie i generowanych opisach.

### **Metodyka/metodologia badań:**

*Proszę przedstawić metody/koncepcje metodologiczne, techniki i narzędzia badawcze, które zostaną wykorzystane. Proszę wyjaśnić ich zasadność.*

W projekcie zostaną wykorzystane metody głębokiego uczenia (deep learning) do analizy obrazów medycznych, ze szczególnym uwzględnieniem technik detekcji obiektów. Zasadniczym podejściem będzie zastosowanie architektury PyTorch oraz YOLO (You Only Look Once), znanej z wysokiej szybkości działania i dobrej skuteczności w lokalizacji oraz klasyfikacji obiektów na obrazach.

### **Metody i koncepcje metodologiczne:**

- **Uczenie z nadzorem:** Modele będą uczone na obrazach oznaczonych przez specjalistów (anotacje zmian patologicznych), co umożliwi systemowi uczenie się zależności między obrazem a diagnozą.
- **Transfer learning:** Zostaną wykorzystane wstępnie wytrenowane modele YOLO, które następnie będą dostosowane do obrazów medycznych. To podejście przyspiesza trening i poprawia skuteczność przy ograniczonej liczbie danych.
- **Augmentacja danych:** Dane obrazowe będą poddane technikom augmentacji (np. obrót, skalowanie, zmiana kontrastu), co zwiększy różnorodność danych treningowych i poprawi odporność modelu na zmienność danych wejściowych.

### **Techniki i narzędzia badawcze:**

- **YOLO (You Only Look Once):** Nowoczesna sieć neuronowa do detekcji obiektów, umożliwiająca jednoczesne lokalizowanie i klasyfikowanie zmian patologicznych.
- **PyTorch:** Popularna biblioteka do głębokiego uczenia, umożliwiająca elastyczne projektowanie i trenowanie modeli.
- **Wskaźniki oceny skuteczności:** Skuteczność modeli będzie oceniana przy pomocy standardowych metryk takich jak: dokładność (accuracy), czułość (sensitivity), swoistość (specificity), F1-score oraz AUC-ROC.

Zastosowane metody są sprawdzone w zadaniach detekcji obiektów i skutecznie wykorzystywane w projektach medycznych. YOLO oferuje znakomitą równowagę między szybkością a dokładnością, co ma kluczowe znaczenie w systemach wspierających decyzje kliniczne. Użycie transfer learningu i augmentacji danych kompensuje ograniczenia dostępności danych medycznych i zwiększa efektywność trenowania modeli.

### **Literatura:**

*Proszę wymienić najważniejsze pozycje bibliograficzne (nie więcej niż 30).*

1. Litjens, G., Kooi, T., Bejnordi, B. E., et al. (2017) – „A survey on deep learning in medical image analysis. Medical Image Analysis”.
2. Esteva, A., Kuprel, B., Novoa, R. A., et al. (2017) – „Dermatologist-level classification of skin cancer with deep neural networks”.
3. Bozek, J., et al. (2021) – „Performance of deep learning algorithms compared to radiologists for chest x-ray interpretation: A systematic review and meta-analysis”.
4. Howard, J., & Gugger, S. (2020) – „Deep Learning for Coders with fastai and PyTorch”.
5. Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012) – „ImageNet classification with deep convolutional neural networks. Advances in Neural Information Processing Systems”.
6. Topol, E. J. (2019) – „Deep Medicine: How Artificial Intelligence Can Make Healthcare Human Again”.
7. Liu, X., Song, L., Liu, S., et al. (2023) – „A unified deep learning framework for multimodal medical image classification”.
8. Wang, Y., Zhang, Y., Lin, Y., et al. (2022) – „YOLOv5 and ResNet-based AI system for automated detection of breast cancer in mammograms. Computers in Biology and Medicine”.
9. Rajaraman, S., Antani, S. (2022) – AI in radiology: Opportunities, challenges, and strategies for implementation”.

***W przypadku gdy opisywany projekt będzie realizowany przez zespół badawczy, proszę wskazać, jaki będzie wkład w jego realizację osoby kandydującej (maksymalnie 1000 znaków dodanych do limitu).***

.....